Engenharia de Dados

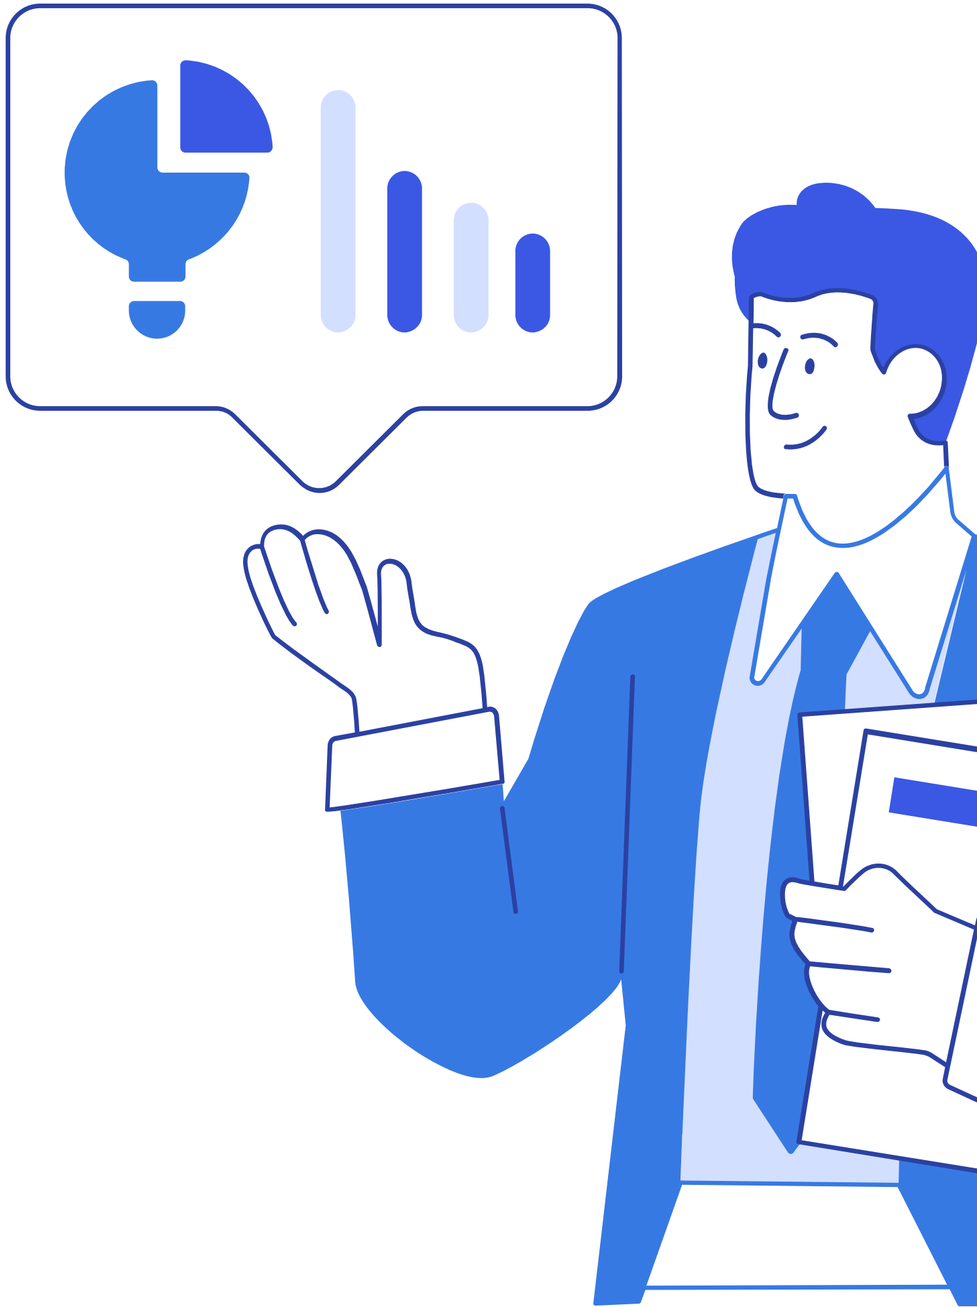

INTEGRANTES

Jonas

Luiz Victor

Émerson

Sumário

- O que é Engenharia de Dados? 01
- Por que ela é necessária? 02
- Como funciona? 03
- Tecnologias e arquiteturas 04
- Aplicações 05
- Estudo de caso 06
- Demonstração 07
- Desafios e limitações 08
- Conclusão 09

O que é Engenharia de Dados?

A Engenharia de Dados é a área da tecnologia responsável por desenvolver processos, arquiteturas e sistemas capazes de coletar, integrar, armazenar, processar, transformar e disponibilizar dados. Seu objetivo é garantir que grandes volumes de informações sejam organizados e tratados de forma confiável, eficiente e acessível, permitindo que esses dados sejam utilizados em análises, aplicações, sistemas de Inteligência Artificial e na tomada de decisões pelas organizações.

O que é um dado?

Na perspetiva da Engenharia, um dado não é apenas um registro isolado, mas um ativo digital com um ciclo de vida rigoroso

- **Dado Bruto (Matéria-prima):** Registros não processados, eventos e ficheiros soltos. Sem contexto e tratamento, não possuem valor de negócio.
- **Informação (Produto):** Dados limpos, estruturados e cruzados, prontos para serem consumidos.
- **O Objetivo Central:** O trabalho da engenharia é construir a infraestrutura que transforma este dado bruto num Ativo Digital confiável e escalável.

De onde vem os dados?

Os dados são gerados continuamente através de múltiplas fontes complexas:

- **Sistemas Internos**: Bases de dados, CRMs e sistemas financeiros (ERP).
- **Aplicações e Web:** Cliques, navegação de utilizadores e interações em tempo real.
- **Dispositivos (IoT):** Sensores industriais, máquinas e telemóveis.
- **Fontes Externas:** Redes sociais e integrações com APIs.

O Problema: Ter dados não é o mesmo que ter informação

Atualmente, as organizações geram volumes massivos de dados a cada segundo. A literatura científica atual (IEEE Access, 2024) discute esse cenário como "Data Mess" (Desordem de Dados) - um gargalo que apenas ferramentas técnicas não conseguem resolver sem governança. O grande desafio atual não é a falta de dados, mas sim a desorganização que impede a análise e a tomada de decisões estratégicas.

Como funciona na prática?

O Pipeline de Dados - Ciclo de Vida

1. **Ingestão:** Coleta de múltiplas fontes (em lotes ou tempo real);
2. **Armazenamento:** Armazenagem dos dados em ambientes escaláveis e seguros;
3. **Processamento/Transformação:** Limpeza, cruzamento, enriquecimento e padronização dos dados;
4. **Disponibilização:** Entrega aos analistas e sistemas de IA.

Data Lake vs Data Warehouse

- **Data Warehouse (O Passado):** Dados altamente organizados e rápidos, mas com uma estrutura rígida e um custo de armazenamento altíssimo.

- **Data Lake (A Reação):** Armazena qualquer tipo de dado bruto a um custo muito baixo. Flexível, mas com alto risco de se transformar num "pântano de dados" inacessível.

As empresas precisavam escolher entre organização cara ou caos barato.

A Evolução Técnica: Data Lakehouse

O Melhor dos Dois Mundos

- Combina a flexibilidade do Data Lake com capacidades analíticas e de gestão associadas ao Data Warehouse.
- Permite ingerir e armazenar grandes volumes de dados, inclusive não estruturados, mantendo recursos para transformação e análise posterior.
- O estudo destaca recursos como consistência, confiabilidade, evolução de esquema e time travel em implementações Lakehouse.
- Evidência experimental: os autores compararam HDFS (Data Lake), Hive (Data Warehouse) e Delta Lakehouse usando dados do IMDb. O Lakehouse não foi o melhor em todas as consultas, mas apresentou vantagens em consultas mais complexas e recursos como Time Travel e Schema Evolution.

Base científica: Harby & Zulkernine (2025), “Data Lakehouse: A survey and experimental study”.

Arquitetura medalhão

Como organizar os dados dentro do Lakehouse

- **Camada Bronze (Cru):** Ingestão de dados no seu estado original (matéria-prima).
- **Camada Prata (Limpo):** Dados filtrados, validados e padronizados.
- **Camada Ouro (Negócio):** Dados agregados, estruturados e prontos para consumo por ferramentas de BI e Modelos de IA.

A Evolução Organizacional: Data Mesh

De dados centralizados para dados orientados a domínios

- **Descentralização:** A responsabilidade pelos dados é distribuída entre os domínios de negócio, em vez de ficar concentrada em uma única equipe de dados.
- **Dados como Produto**: Cada domínio é responsável por disponibilizar dados confiáveis, documentados e acessíveis para outros consumidores.
- **Infraestrutura Self-Service:** A plataforma de dados deve permitir que os próprios domínios publiquem e consumam dados sem depender constantemente de uma equipe central.

Base científica: Goedegebuure et al., “Data Mesh: A Systematic Gray Literature Review”.

Comparação das arquiteturas

WAREHOUSE/LAKE

Tecnologias isoladas (Alto custo vs. Desorganização).

DATA LAKEHOUSE

Solução Tecnológica Centralizada

DATA MESH

Solução Organizacional Descentralizada

Aplicações

STREAMING E PERSONALIZAÇÃO

Spotify / Netflix

- Histórico de consumo e interações
- Pipelines alimentam sistemas de recomendação
- Processamento de grandes volumes de eventos

FINANÇAS E FRAUDES

Bancos / Fintechs

- Transações processadas continuamente
- Cruzamento de histórico, localização e comportamento
- Detecção de padrões suspeitos

Aplicações

Estudo recente (arXiv, 2026) sugere que arquiteturas modernas, como o Lakehouse, são importantes para sustentar ecossistemas de IA generativa confiáveis.

LOGÍSTICA E MOBILIDADE

Uber / iFood

- Eventos de pedidos e viagens em tempo real
- Oferta e demanda
- Rastreamento e alocação de entregadores/motoristas
- Análise para otimização da operação

Inteligência Artificial

Machine Learning / IA Generativa

- Dados precisam ser coletados, limpos e transformados
- Pipelines alimentam treinamento e inferência
- Qualidade e governança impactam os modelos

Estudo De Caso

Ifood

O CENÁRIO

Gestão de milhares de registros de dados, provenientes de diferentes partes da operação aplicativo do consumidor, aplicativo do entregador, restaurantes e parceiros.

O PROBLEMA

Muitos pipelines para manter, maior complexidade operacional, custos de processamento e armazenamento, dificuldade para evoluir os fluxos de dados e maior esforço das equipes de Engenharia de Dados

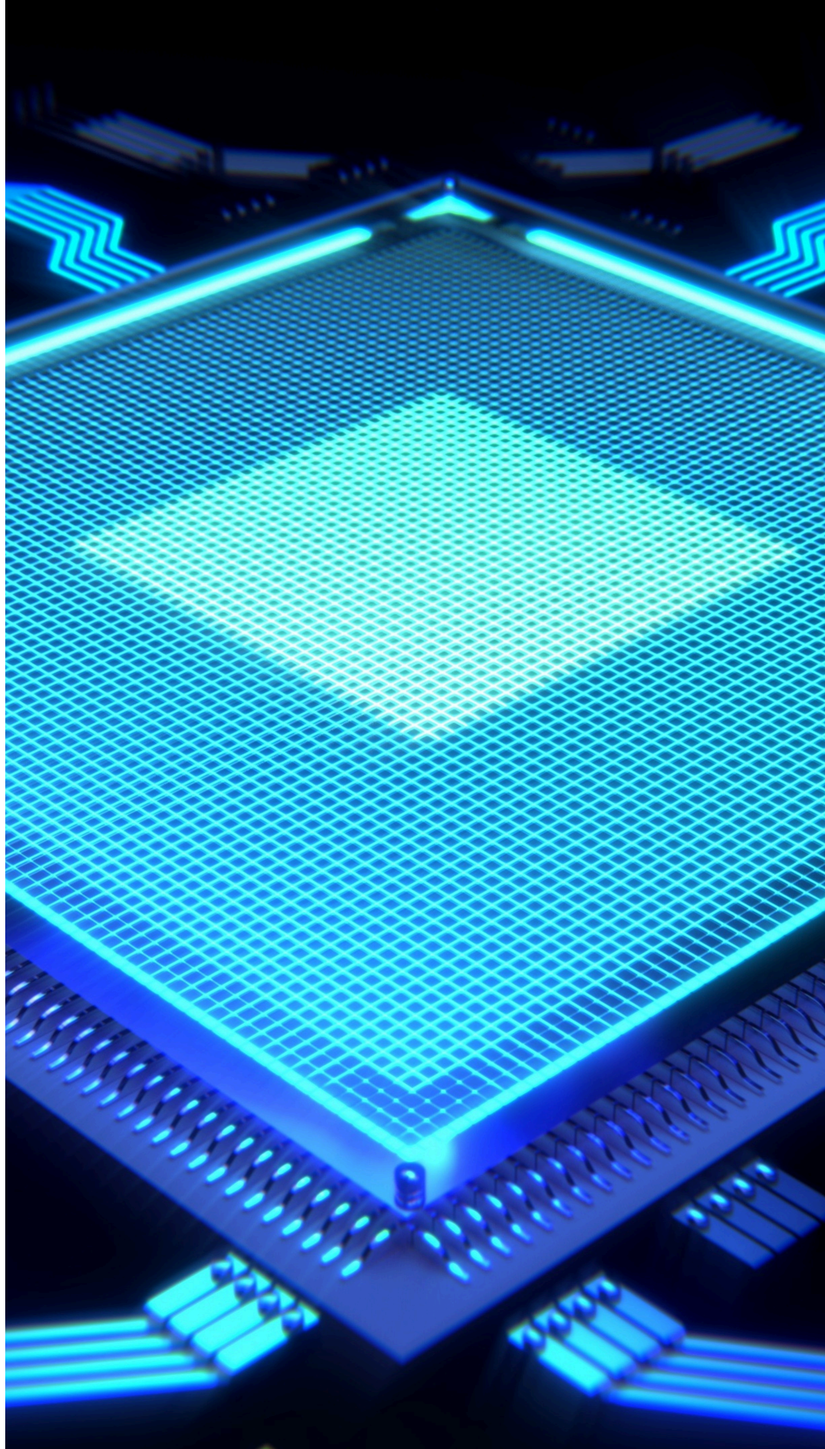

Estudo De Caso

A Solução

O iFood adotou o Data Mesh combinado com uma arquitetura Lakehouse e a abordagem medalhão para dar autonomia aos times e organizar os dados por domínios.

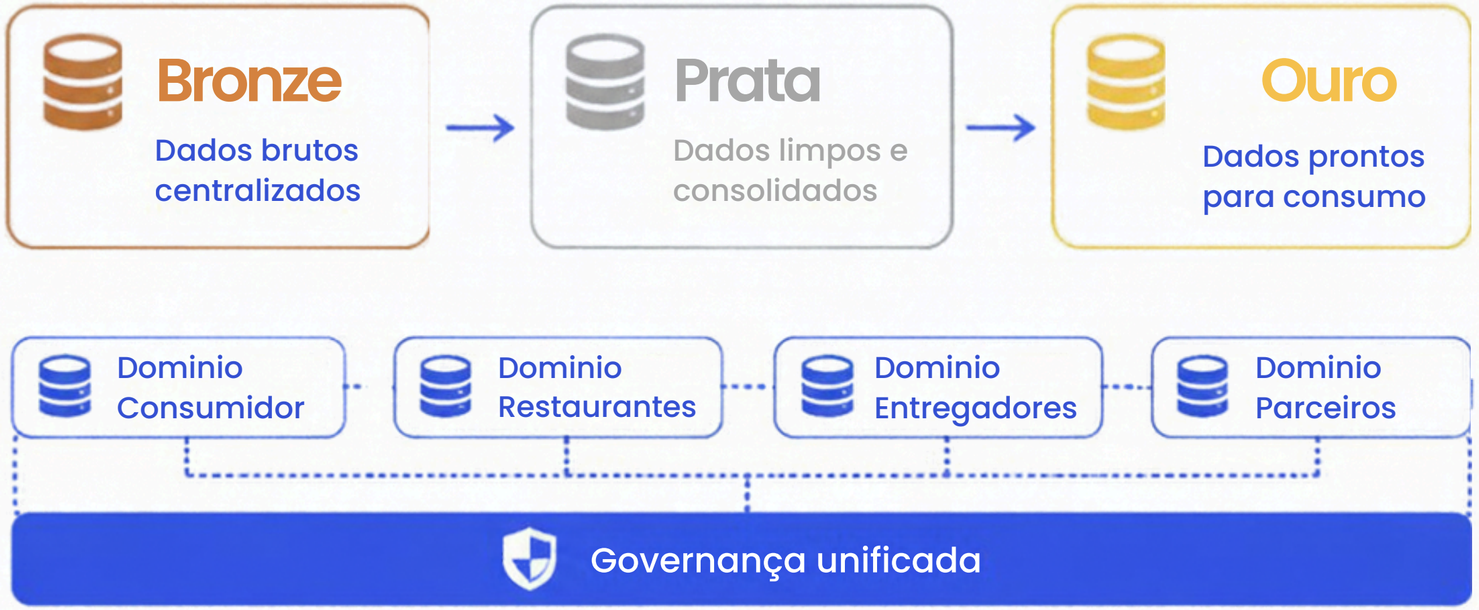

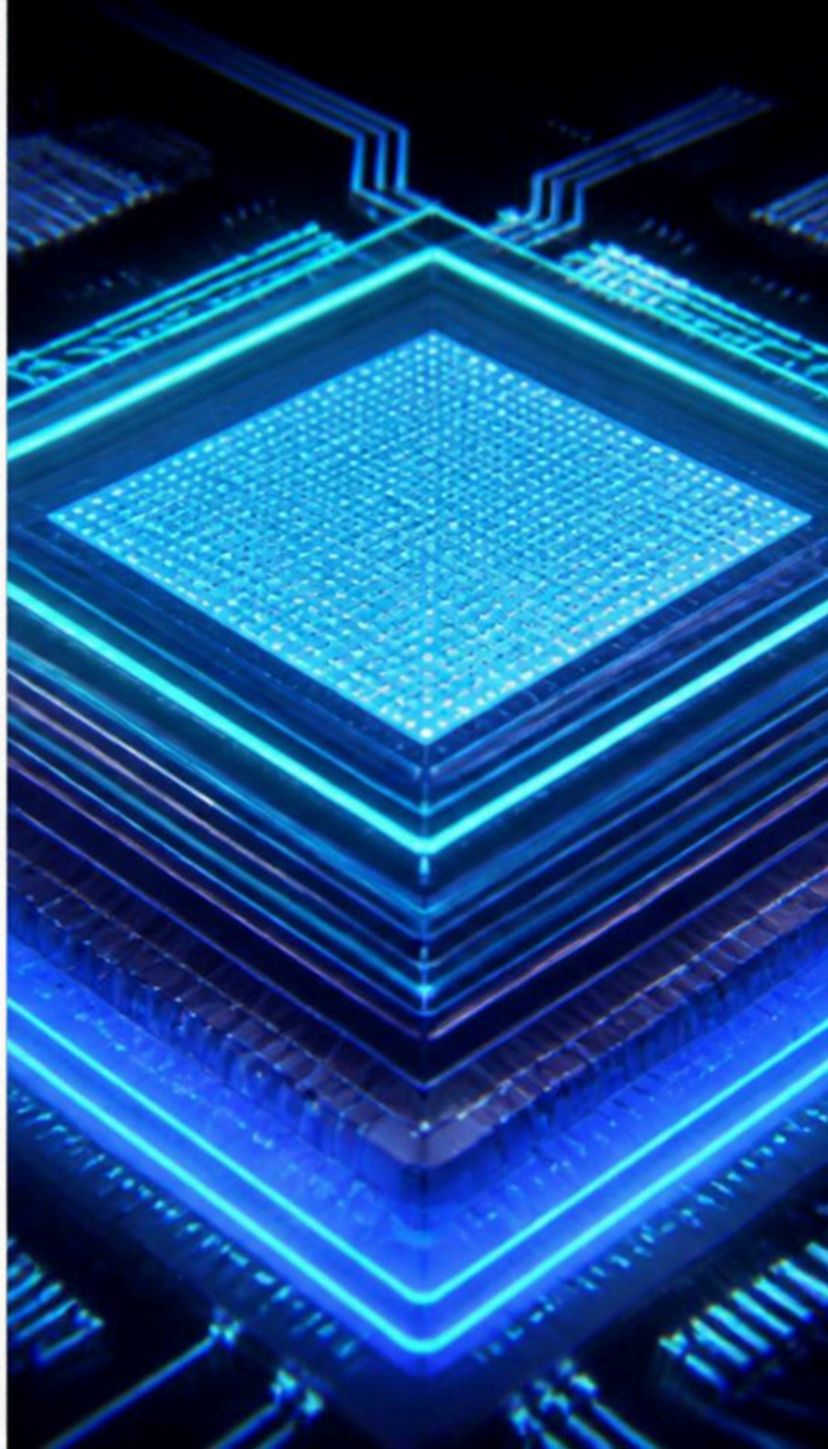

Estudo De Caso

Ifood

Os Resultados

70%

de redução aproximada no esforço de manutenção dos pipelines

67%

de redução nos custos

30%

de redução no tempo de codificação com a abordagem declarativa

mais velocidade, escalabilidade e autonomia para os times de dados.

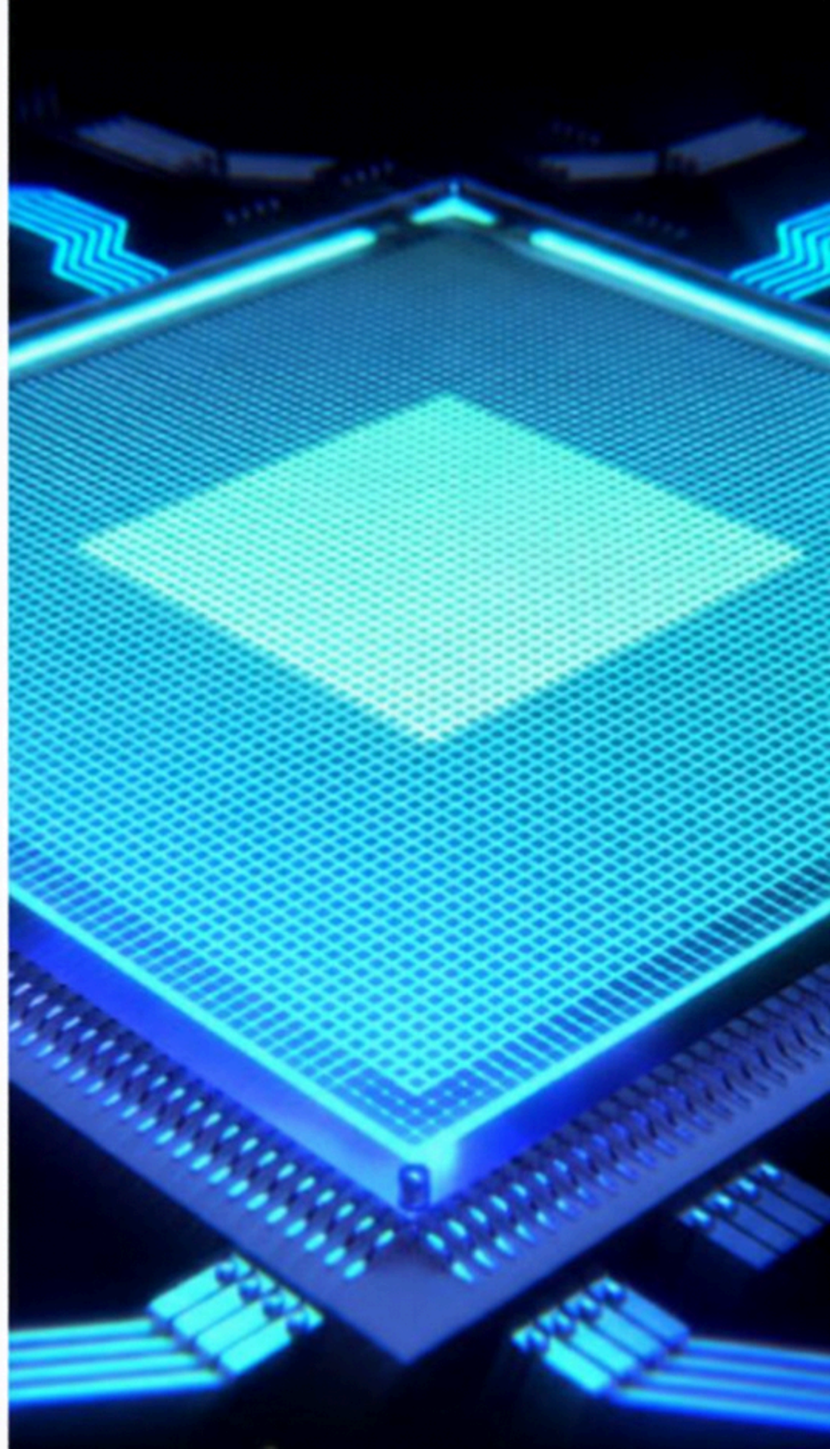

Estudo De Caso

Conclusão

Engenharia de Dados transforma complexidade em escala.

Uma arquitetura bem estruturada, com autonomia dos domínios e governança, reduz custos, acelera decisões e sustenta o crescimento do negócio.

Análise Crítica: Os dados são do case oficial da Databricks (fornecedora da tecnologia). Por haver interesse comercial, os números de redução de custo devem ser lidos com cautela sobre possíveis custos ocultos de migração.

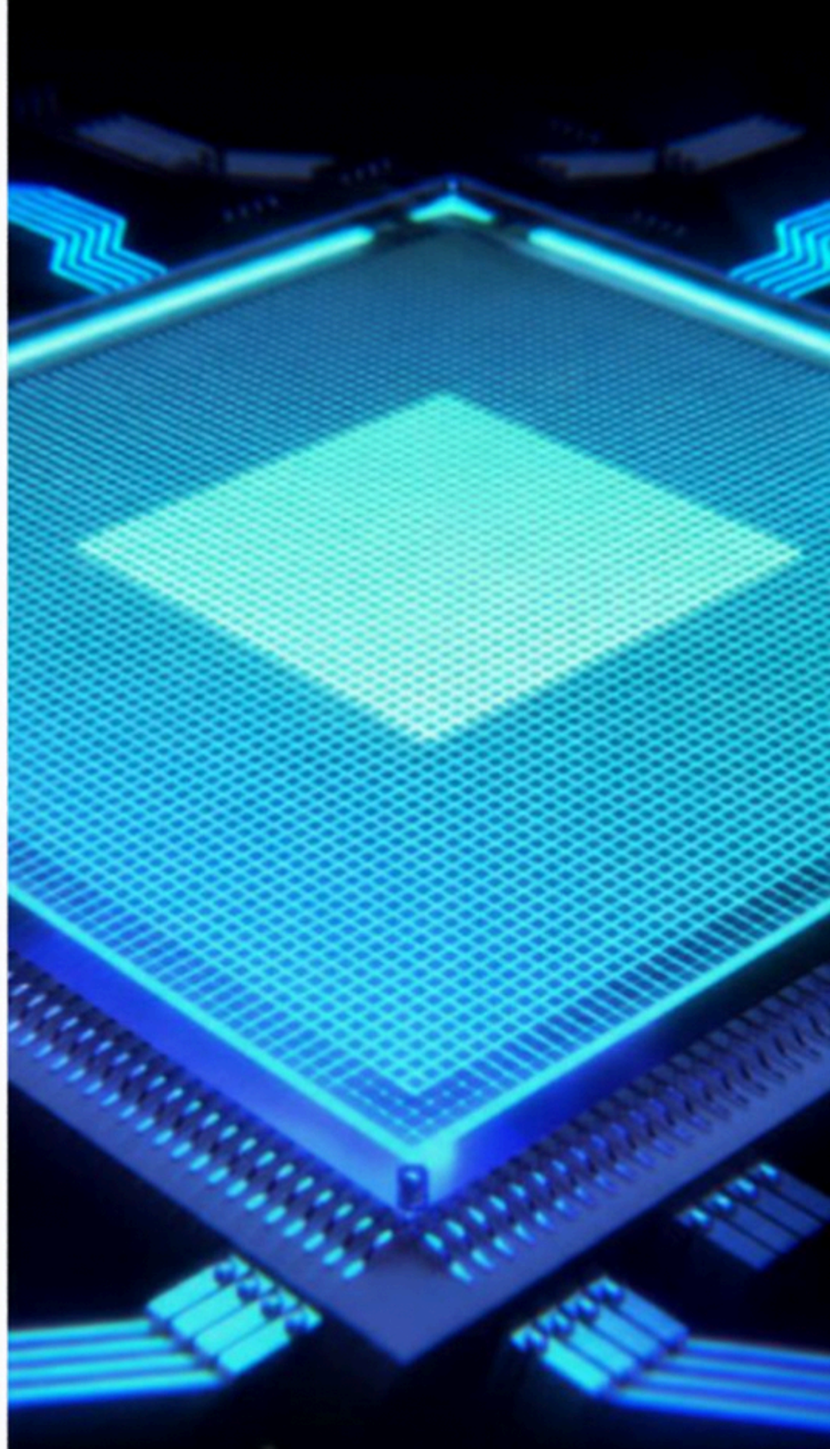

Demonstração

https://engenharia-de-dados-arquitetura-medalhao.lovable.app/

Riscos e limitações na prática

Com base nos estudos, Data Mesh e Lakehouse não resolvem problemas automaticamente. O sucesso depende de disciplina, governança e maturidade organizacional.

A descentralização pode aumentar a complexidade.
Mais dominios, interfaces e fluxos exigem coordenação para evitar fragmentação e retrabalho.

A autonomia dos domínios exige padrões, papéis e governança.
Sem contratos de dados, catálogo, qualidade e políticas claras, a autonomia vira desordem.

Riscos e limitações na prática

Risco de formação de um "Pântano de Dados" (Data Swamp). Apesar da flexibilidade, armazenar tudo sem uma estruturação rigorosa em camadas (como a arquitetura medalhão) torna os dados inacessíveis e inúteis para o negócio.

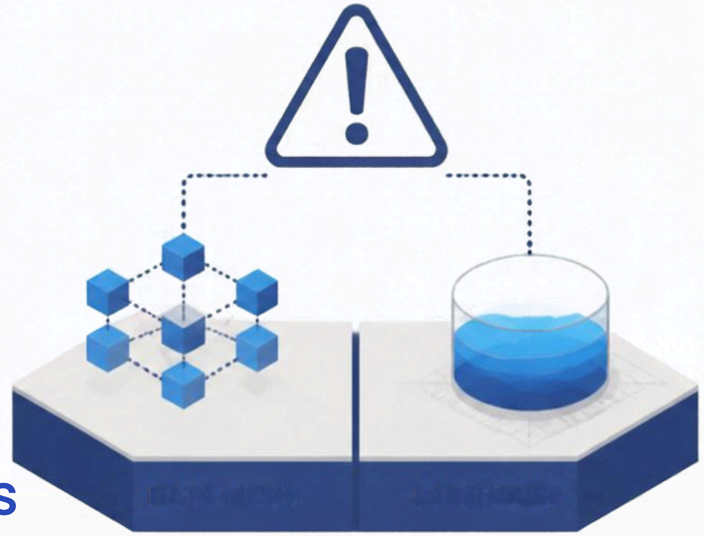

Custos ocultos e curva de aprendizado. A infraestrutura em nuvem e ferramentas modernas exigem equipes altamente capacitadas. Consultas mal otimizadas e duplicação de esforços entre domínios podem gerar custos imprevisíveis.

Referências científicas

BODE, J.; KÜHL, N.; KREUZBERGER, D.; HOLTMANN, C. Towards avoiding the data mess: Industry insights from data mesh implementations. **IEEE Access**, 2024.

GOEDEGEBURE ET AL. DATA MESH: A SYSTEMATIC GRAY LITERATURE REVIEW. **ACM COMPUTING SURVEYS.** DOI: 10.1145/3687301.

HARBY, A.; ZULKERNINE, M. DATA LAKEHOUSE: A survey and experimental study. **Information Systems,** v. 127, 2025. DOI: 10.1016/j.jis.2024.102460.

Referências complementares

1. **WHAT WENT WRONG WITH DATA LAKES?**
A 15-Year Reality Check from the Field.
arXiv, 2026.
Disponível em: https://arxiv.org/html/26.6.08266v1.

2. **BEYOND THE DATA MESH ILLUSION:**
Designing Modern AI-augmented Lakehouses.
arXiv:2605.27131, 2026.

3. **CASE IFOOD — TRANSFORMING DATA TO ELEVATE FOOD DELIVERIES AND EXPERIENCES.**
https://www.databricks.com/customers/ifood/lakeflow-declarative-pipelines

Conclusão

Engenharia de Dados transforma complexidade em escala.

O valor não está apenas em armazenar dados, mas em criar uma base confiável, governada e escalável que sustenta decisões melhores e impulsiona a inovação.

Arquiteturas como Lakehouse e abordagens como Data Mesh ampliam possibilidades, mas exigem governança, qualidade, segurança e maturidade organizacional.

Obrigado!

Perguntas?